Actividad 5 | Entrenamiento y registro de modelos

Reporte técnico · Clasificación supervisada · Dataset bancario sintético · 25 de octubre de 2026

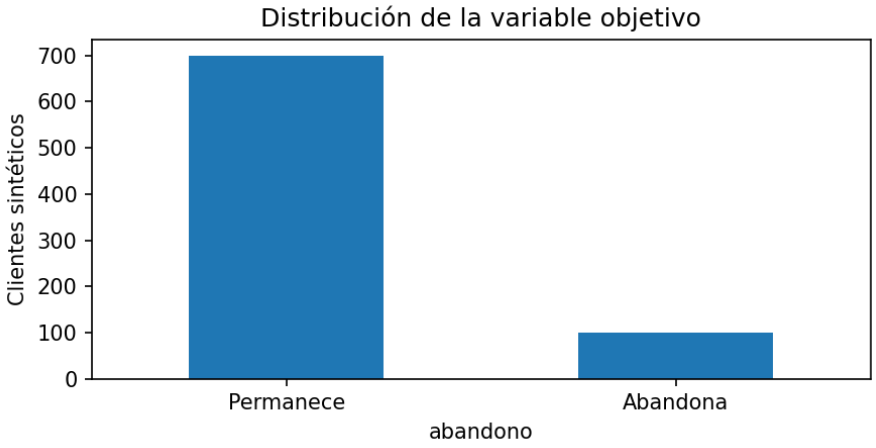
Alcance: demostración académica. No se utilizan datos reales ni se propone automatizar decisiones sobre clientes.

1. Contexto y Design Thinking

Necesidad hipotética: anticipar posibles abandonos para orientar acciones de servicio. Se define una clasificación binaria, se comparan una referencia interpretable (regresión logística) y un ensamble no lineal (random forest), y se prototipa una evaluación reproducible. La etapa de empatía es conceptual: no hubo entrevistas ni validación con clientes.

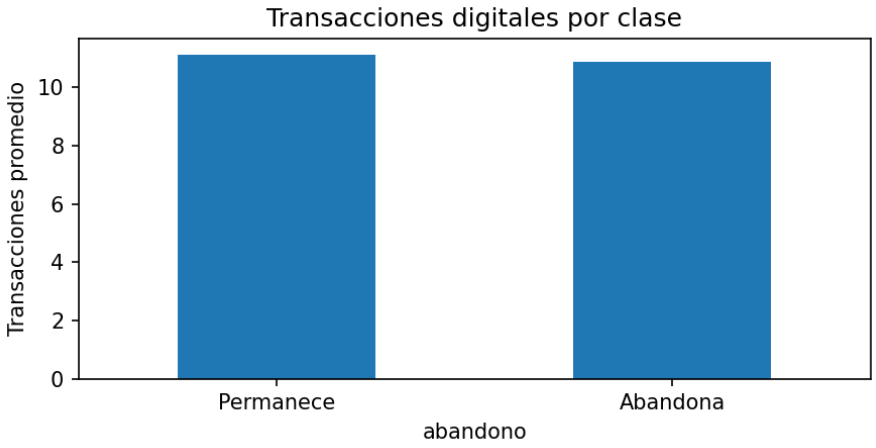
2. Dataset, fuente y supuestos

Fuente: simulación propia reproducible (semilla 20261025). **800 registros**, 100 etiquetas positivas (12.5%). Variables: id sintético, edad, antigüedad, saldo MXN, productos, uso de app, reclamaciones, transacciones digitales por mes, estado activo, región y segmento y abandono. La etiqueta fue generada mediante una función logística artificial: el experimento no valida un patrón bancario real. Diccionario completo: datos/DICCIONARIO.md.



3. Limpieza y estandarización

Se eliminan duplicados por identificador; edades fuera de 18 a 100 se excluyen; categorías de región y segmento se normalizan; el objetivo se valida como binario. La imputación numérica por mediana, la categórica por moda, el escalado estándar y la codificación one-hot se ajustan dentro del pipeline de cada fold para evitar fuga de datos. El identificador no se usa como predictor.



4. Versionamiento y reproducibilidad

Se conservan datos originales y limpios en carpetas separadas. CHANGELOG.md registra la versión 1.0.0, la semilla y las reglas de limpieza. El código fuente se versiona en GitHub; las ejecuciones MLflow locales se excluyen de Git mediante .gitignore. Para replicar, instalar requirements.txt y ejecutar python fuentes/train.py.

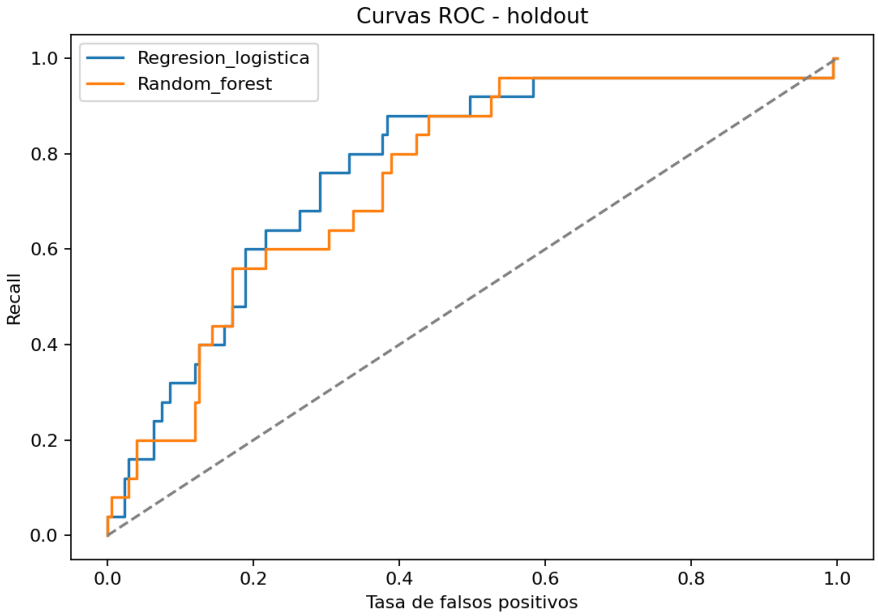
5. Modelos, búsqueda y validación

Separación estratificada entrenamiento/prueba 75/25 (random_state=42). GridSearchCV con 5 folds estratificados optimiza ROC-AUC en entrenamiento. Regresión logística: C ∈ {0.1,1,10} y class_weight ∈ {None, balanced}; random forest: n_estimators ∈ {100,200}, max_depth ∈ {4,8,None}, min_samples_leaf ∈ {1,5}. El test reservado se usa únicamente para la comparación final.

6. Métricas obtenidas: prueba reservada

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Regresion logistica	0.875	0.000	0.000	0.000	0.771
Random forest	0.875	0.000	0.000	0.000	0.748

Métricas medidas sobre 120 casos de prueba. Precision, recall y F1 corresponden a la clase positiva (abandono=1), no al promedio macro.



7. Comparación estadística

Regresion logistica: ROC-AUC de validación cruzada 0.732 ± 0.083 (desviación estándar de 5 folds); ROC-AUC CV medio 0.732. Mejor configuración: {"clasificador__C": 0.1, "clasificador__class_weight": null}.

Random forest: ROC-AUC de validación cruzada 0.708 ± 0.066 (desviación estándar de 5 folds); ROC-AUC CV medio 0.708. Mejor configuración: {"clasificador__max_depth": 4, "clasificador__min_samples_leaf": 1, "clasificador__n_estimators": 200}.

La diferencia observada entre algoritmos es descriptiva, no una prueba de significancia: solo se usó una partición de prueba y un conjunto sintético. Para inferencia estadística robusta se requieren repeticiones con distintas semillas e intervalos de confianza o pruebas pareadas apropiadas.

8. Registro de experimentos MLflow

El script está instrumentado para registrar por algoritmo parámetros seleccionados, accuracy, precision, recall, F1, ROC-AUC, AUC de CV, matrices de confusión, predicciones y modelo serializado. **Limitación de esta entrega:** MLflow no pudo instalarse en el entorno de elaboración (sin acceso a paquetes externos); por tanto NO se afirma que existan runs MLflow ejecutados ni capturas auténticas. El notebook de Colab incluye celdas para ejecutar y verificar al menos dos runs; guía de capturas en evidencias/GUIA_MLFLOW.md.

9. Decisión y riesgos

Para esta prueba sintética, ambos modelos obtienen F1=0 y recall=0 para la clase abandono con umbral 0.5. Ninguno es recomendable sin ajustar umbral y estrategia de desequilibrio; la regresión logística tiene ROC-AUC ligeramente mayor. La decisión depende del costo de falsos positivos, calibración y validación externa. Riesgos: datos simulados, deriva, representatividad, sesgos, explicabilidad y protección de datos.

10. Deuda técnica y MLOps

Pendientes: ejecutar MLflow y guardar evidencia real; fijar versiones y hashes de datos; agregar tests y CI; monitorear drift, calidad y sesgos; registrar aprobación de modelo, responsables y política de reentrenamiento; comparar rendimiento con datos autorizados y documentar gobierno del dato. No desplegar el prototipo en producción.

11. Referencias de contexto

Materiales académicos proporcionados por el estudiante: Tema 11 (T11.pdf), preparación y versionamiento de datos; Tema 12 (T12.pdf), entrenamiento, validación y seguimiento de experimentos. Implementación técnica adicional: scikit-learn y MLflow (documentación de bibliotecas).