Actividad 5 | Reporte técnico final

Predicción de abandono bancario · Clasificación supervisada · Google Colab · GridSearchCV · MLflow

Estado: entrenamiento ejecutado y registro MLflow verificado mediante salidas y capturas proporcionadas por el estudiante. Alcance: investigación académica con datos sintéticos; no es un sistema apto para decisiones bancarias reales.

1. Caso de uso y enfoque metodológico

Problema: clasificar la variable binaria abandono (1 = abandono; 0 = permanencia) para explorar señales de deserción. En términos de design thinking, la necesidad hipotética es anticipar posibles pérdidas de relación comercial, pero sin intervenir clientes ni utilizar datos personales reales. La solución se evalúa por su capacidad de distinguir ambas clases y detectar la clase minoritaria.

2. Dataset, fuente y diccionario de datos

Fuente: dataset sintético generado para esta actividad (versión v1_sintetico); 800 filas y 11 columnas. La distribución observada en Colab fue 700 casos sin abandono y 100 con abandono (12.5%). No procede de una entidad financiera ni acredita relaciones causales.

Campo	Descripción
cliente_id	Identificador sintético; excluido de predictores
edad / antiguedad_anios	Edad y antigüedad de relación, en años
num_productos / saldo_mxn	Productos contratados y saldo simulado en MXN
cliente_activo	Indicador de actividad
transacciones_digitales_mes	Frecuencia mensual de transacciones digitales
reclamaciones_12m	Reclamaciones en los últimos 12 meses
region / segmento	Categorías de región y segmento
abandono	Variable objetivo: 0 o 1

3. Limpieza, estandarización y control de fugas

La preparación mediante fuentes/datos_prep.py genera datos/datos_limp/clientes_limpios_v1.csv desde datos/datos_ini/clientes_sinteticos_v1.csv. El proceso documentado elimina duplicados por identificador, normaliza categorías, convierte tipos y filtra edades o etiquetas inválidas. En los pipelines se aplica imputación numérica por mediana, categórica por moda, escalado estándar de numéricas y codificación one-hot de categóricas. El ajuste ocurre dentro de validación cruzada, evitando que estadísticas del conjunto de prueba contaminen el entrenamiento.

4. Versionamiento y reproducibilidad

Se utiliza GitHub para el código y archivos del proyecto, README.md y CHANGELOG.md para trazabilidad y la etiqueta dataset_version=v1_sintetico en MLflow. Semilla aleatoria 42, partición estratificada 75/25 (600 entrenamiento; 200 prueba) y 5 folds estratificados. La base local SQLite mlflow.db y los artefactos requieren respaldo explícito antes de que expire la sesión de Colab. Las correcciones del notebook y de train.py se informaron como publicadas en GitHub por el estudiante; no se hizo auditoría independiente de la última versión remota.

5. Exploración: patrones y anomalías

La exploración confirmó un desbalance 7:1. El boxplot de transacciones digitales por mes mostró medianas cercanas a 11 en ambos grupos y valores atípicos altos, sin separación visual clara entre abandono y permanencia. Es una observación descriptiva, no una prueba de significación ni de importancia predictiva.

6. Algoritmos, búsqueda y mejores hiperparámetros

Regresión logística: búsqueda de C en {0.1, 1, 10} y class_weight en {None, balanced}. Random forest: n_estimators en {100, 200}, max_depth en {4, 8, None} y min_samples_leaf en {1, 5}. Se seleccionaron hiperparámetros mediante GridSearchCV con ROC-AUC como criterio, cinco folds estratificados y refit sobre entrenamiento.

Regresion_logistica: clasificador__C=0.1, clasificador__class_weight=None

Random_forest: clasificador__max_depth=4, clasificador__min_samples_leaf=1, clasificador__n_estimators=200

7. Métricas definitivas de la prueba reservada

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	CV AUC (DE)
Regresion logistica	0.8750	0.0000	0.0000	0.0000	0.7707	0.7322 (0.0834)
Random forest	0.8750	0.0000	0.0000	0.0000	0.7477	0.7083 (0.0664)

La regresión logística alcanzó ROC-AUC 0.7707 frente a 0.7477 para random forest; diferencia descriptiva de 0.0231. Ambos modelos presentan precision, recall y F1 de 0 para abandono al umbral por defecto. La accuracy de 0.875 coincide con la prevalencia de la clase mayoritaria, por lo que no constituye evidencia de detección útil de abandono.

8. Curvas ROC — figura aportada por el estudiante

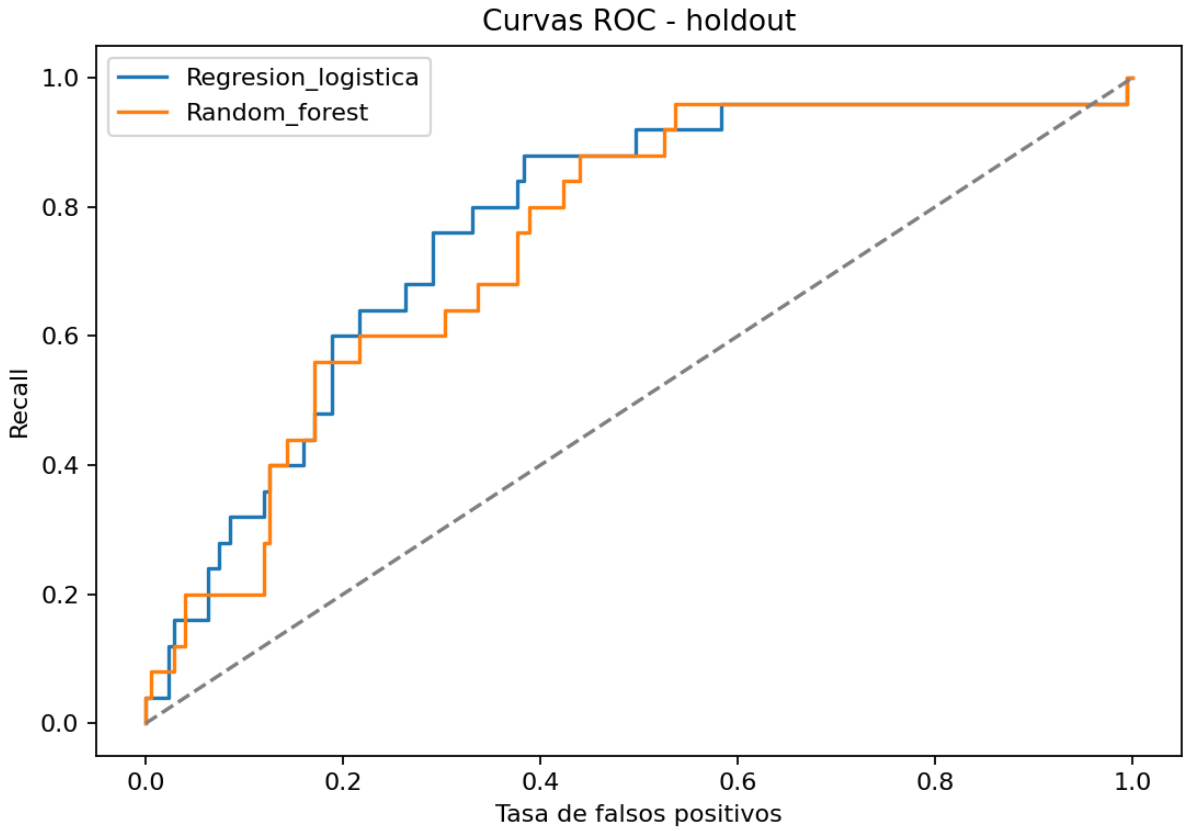


Figura 1. Curvas ROC de holdout suministradas con la entrega. La imagen no contiene valores AUC en la leyenda. Los ROC-AUC numéricos se toman del CSV final y de MLflow; no se recalcularon a partir de la imagen. Para certificar correspondencia exacta debe regenerarse la curva desde las probabilidades y etiquetas del mismo holdout.

9. Comparación estadística e incertidumbre

El reporte preliminar documentó una prueba t pareada exploratoria sobre los cinco folds (t=1.193, p=0.2987). Ese cálculo no fue recalculado a partir del CSV final, que solo contiene medias y desviaciones estándar; tampoco equivale a evidencia confirmatoria por la dependencia entre folds. La diferencia de ROC-AUC observada no demuestra superioridad estadística. Se recomiendan validación cruzada repetida, intervalos de confianza y validación externa/temporal.

10. Evidencia de seguimiento MLflow

La ejecución en Colab creó el experimento Actividad5_Churn_Sintetico con backend SQLite. El estudiante compartió una tabla con cuatro runs: FINISHED para Regresion_logistica, Random_forest y comparacion_global, y FAILED para un intento previo de regresión logística. Se verificaron parámetros, métricas y archivos de predicción y confusión; además se mostraron identificadores de modelos asociados a las dos ejecuciones exitosas.

Ejecución	Estado	Contenido comprobado
Regresion_logistica	FINISHED	C=0.1; class_weight=None; métricas; confusión; predicciones; model ID
Random_forest	FINISHED	max_depth=4; min_samples_leaf=1; n_estimators=200; métricas; model ID
comparacion_global	FINISHED	comparacion_estadistica.json; comparacion_modelos.csv; curvas_roc.png
Regresion_logistica (previa)	FAILED	Intento interrumpido al guardar modelo

La captura de evidencias/01_mlflow_ejecuciones.png, evidencias/02_mlflow_parametros_metricas.png, evidencias/03_mlflow_artefactos.png y evidencias/04_mlflow_modelos.png se informó como publicada en GitHub. La evidencia se revisó a partir de las capturas de la conversación; este PDF no afirma haber auditado el almacenamiento remoto ni el contenido binario de los modelos. El Model ID prueba asociación con la ejecución, no necesariamente inscripción en Model Registry.

11. Deuda técnica, riesgos y prácticas MLOps

Riesgos del modelo: datos sintéticos, prevalencia construida, ausencia de validación temporal, recall cero para abandono, posible drift y sesgos al transferirlo a poblaciones reales. No debe desplegarse para decisiones automatizadas. Deuda técnica: cambios manuales en Colab, diferencias entre documentación y scripts, persistencia temporal de SQLite, dependencias con avisos de compatibilidad y uso de cloudpickle (riesgo al deserializar modelos no confiables).

Plan MLOps: (1) asegurar entorno reproducible y pruebas automáticas; (2) respaldar base SQLite y artefactos en almacenamiento persistente; (3) versionar datasets con hashes y registrar commit de Git; (4) experimentar con umbrales, class_weight, PR-AUC y calibración; (5) evaluar estabilidad, sesgos y desempeño por segmento; (6) establecer monitoreo de drift, alertas, responsables y revisión humana antes de cualquier piloto.

12. Decisión y próximos experimentos

Regresión logística es el candidato exploratorio por su ROC-AUC mayor y relativa interpretabilidad, pero la decisión operativa es no desplegar ninguno hasta mejorar recall de abandono y demostrar estabilidad fuera del dataset sintético. Debe priorizarse el costo de falsos negativos y evaluar la precisión-recall bajo umbrales seleccionados exclusivamente con datos de validación.

Fuentes y trazabilidad

Base académica: materiales T11 y T12 aportados por el estudiante (preparación, versionamiento, entrenamiento y MLOps). Datos experimentales: comparacion_modelos(1).csv y curvas_roc.png entregados en esta conversación; salidas de Colab y MLflow proporcionadas por el estudiante. Código de referencia: fuentes/train.py y documentación original de Actividad5.