Actividad 5 | Reporte técnico de Machine Learning

Caso de uso: predicción de abandono de clientes bancarios. **Datos sintéticos y ejercicio académico.** Fecha: 25 de octubre de 2026. Estado: entrenamiento y evaluación ejecutados; seguimiento MLflow preparado pero pendiente de validación en un entorno con MLflow instalado.

1. Problema, fuente y supuestos

Se generaron 800 registros sintéticos con semilla 2026; proporción de abandono 12.5%. Los datos no proceden de BBVA ni de clientes reales. El objetivo es identificar clientes con abandono=1. Las relaciones entre variables fueron diseñadas artificialmente y no constituyen evidencia de causalidad.

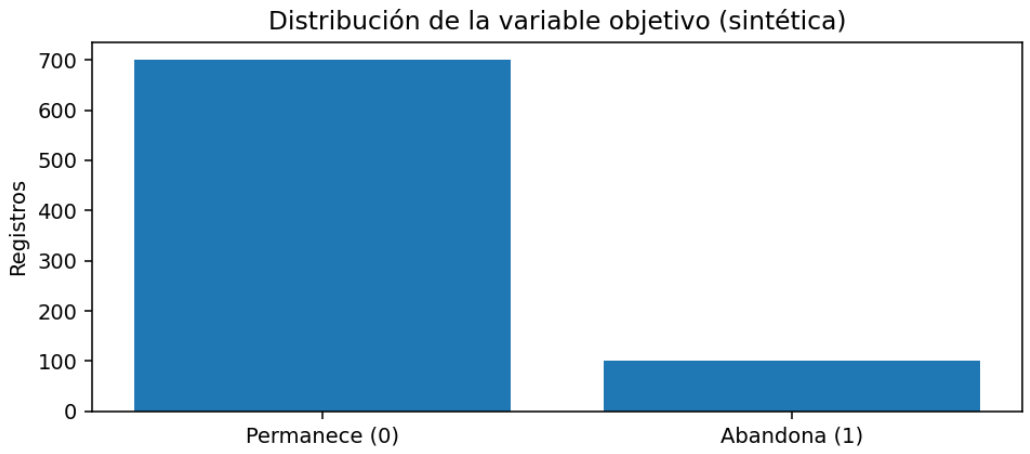
2. Diccionario de datos

Campo	Definición / unidad
cliente_id	Identificador sintético; excluido del modelo
edad, antiguedad_anios	Edad y años de relación
num_productos, saldo_mxn	Número de productos y saldo simulado en MXN
cliente_activo, transacciones_digitales_mes	Indicador de actividad y frecuencia digital
reclamaciones_12m	Número de reclamaciones en 12 meses
region, segmento	Variables categóricas sintéticas
abandono	Objetivo binario: 1 abandona, 0 permanece

3. Limpieza, reglas y versionamiento

Se eliminan duplicados por identificador, se normalizan mayúsculas y espacios en categorías, se convierten tipos numéricos y se descartan edades fuera de 18-100 o etiquetas inválidas. Se preservan nulos en datos limpios; imputación numérica (mediana), categórica (moda), escalado estándar y one-hot se ajustan únicamente dentro de cada fold del pipeline para evitar fuga de información. Dataset v1 y cambios documentados en CHANGELOG.md.

4. Exploración y anomalías



Se aprecia desbalance de clases; por ello accuracy aislada resulta insuficiente. Los faltantes simulados en saldo, transacciones y segmento se procesan dentro del pipeline.

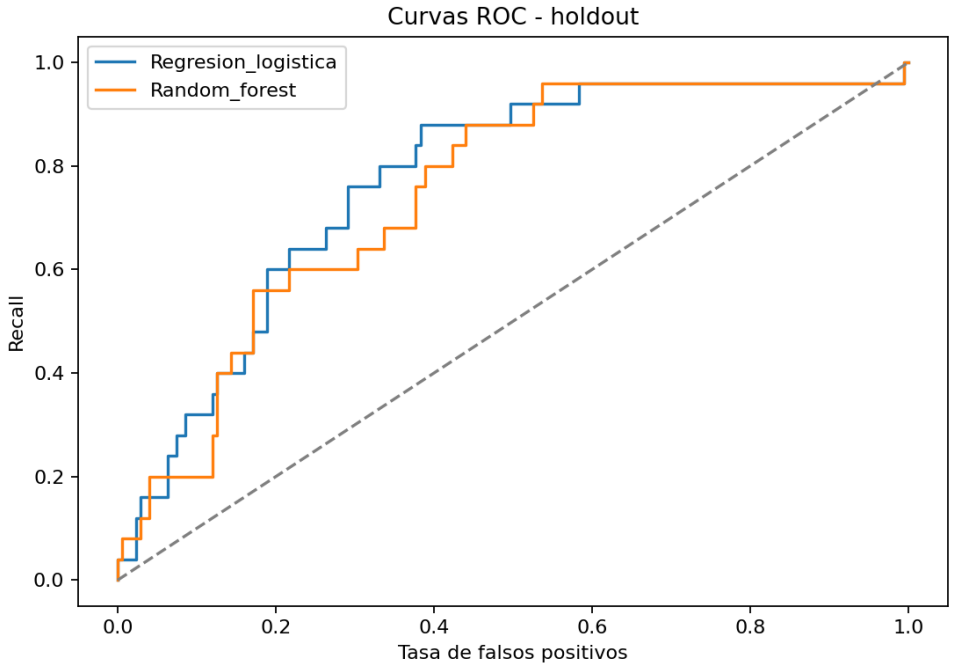
5. Modelos, hiperparámetros y validación

Se comparan regresión logística (C: 0.1, 1, 10; class_weight: None/balanced) y random forest (n_estimators: 100/200; max_depth: 4/8/None; min_samples_leaf: 1/5). Separación estratificada 75/25 (semilla 42). GridSearchCV con 5 folds estratificados, optimizando ROC-AUC en entrenamiento; evaluación única en holdout.

6. Resultados obtenidos

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	CV AUC
Regresion logistica	0.875	0.000	0.000	0.000	0.771	0.732
Random forest	0.875	0.000	0.000	0.000	0.748	0.708

Ambos modelos presentan recall=0 y F1=0 para abandono al umbral 0.5: clasifican todos los ejemplos de prueba como no abandono. No es adecuado recomendar su despliegue; se requiere calibrar umbrales y ponderar costos de falsos negativos.



7. Comparación estadística

Comparación exploratoria pareada de ROC-AUC por fold (cinco particiones compartidas): estadístico t=1.193; p=0.2987. Con cinco folds correlacionados, este contraste no proporciona evidencia confirmatoria de superioridad. Se recomienda repetir CV con distintas semillas y estimar intervalos de confianza sobre datos externos.

8. MLflow: instrumentación y evidencia

El archivo fuentes/train.py configura un experimento local de MLflow, registra parámetros seleccionados, métricas, matrices de confusión, predicciones, curvas ROC y artefacto del modelo. **No se ejecutó MLflow en este entorno porque no estaba instalado ni disponible para descarga.** Por tanto, no se presentan capturas falsas. La guía

evidencias/GUIA_CAPTURAS.md especifica las cuatro capturas auténticas que deben obtenerse tras ejecutar el notebook en Colab o localmente.

9. Deuda técnica, riesgos y MLOps

Limitaciones: datos sintéticos, prevalencia artificial, ausencia de validación temporal, posible drift, desbalance y errores de clasificación en clase positiva. Deuda técnica: no hay CI/CD, monitoreo de drift, pruebas de sesgo, calibración ni registro remoto seguro. Próximos pasos: fijar dependencias exactas, añadir pruebas unitarias, controlar versiones de datasets por hash/DVC, repetir CV, calibrar umbral, revisar equidad y definir aprobación humana.

10. Conclusión

La actividad demuestra entrenamiento, grid search, validación cruzada y evaluación reproducibles, pero los modelos no alcanzan una sensibilidad útil para detectar abandono con umbral 0.5. La evidencia de MLflow requiere una ejecución adicional. El prototipo no debe utilizarse para decisiones reales.

Referencias y materiales

Materiales académicos adjuntos: Tema 11 (preparación/versionamiento y entrenamiento) y Tema 12 (experimentos, MLflow y MLOps). Documentación técnica: scikit-learn y MLflow. Los resultados provienen de la ejecución local registrada en resultados/.